



文章一种深度学习GRU自动编码器组合用于猪的早期呼吸系统疾病检测，采用多种环境传感器

Jake Cowton ^{1,2,*}, Ilias Kyriazakis ² , Thomas Plötz ^{3,†} and Jaume Bacardit ¹

¹ 跨学科计算与复杂生物系统研究组，计算机学院，纽卡斯尔大学，纽卡斯尔 NE17RU，英国；
jaume.bacardit@newcastle.ac.uk² 农业学院，自然与环境科学学院，纽卡斯尔大学，纽卡斯尔 NE1
7RU，英国；ilias.kyriazakis@newcastle.ac.uk³ 开放实验室，纽卡斯尔大学，纽卡斯尔 NE17RU，英
国；thomas.plotz@gatech.edu* 通讯作者：j.cowton2@newcastle.ac.uk

† 当前地址：交互计算学院，佐治亚理工学院，亚特兰大，GA 30318，美国

收到：2018年6月22日；接受：2018年7月31日；发表：2018年8月2日



摘要：我们设计并评估了一种无假设的、基于深度学习的动物健康监测方法，特别针对基于环境传感器数据的生长猪呼吸系统疾病的早期检测。该方法使用了两个包含门控循环单元（GRU）的循环神经网络（RNN），用于构建一个自动编码器（GRU-AE），将来自各种传感器的环境数据输入其中以检测异常。自动编码器是一种经过训练以重建其输入模式的网络。通过使用不会导致呼吸系统疾病发生的环境数据训练GRU-AE，不符合“健康环境数据”模式的数据会产生更大的重建误差。所有重建误差均使用基于阈值的异常检测方法（该检测方法经过粒子群优化算法PSO优化）进行标注，从而触发警报。GRU-AE方法的结果优于最先进技术，当预测结果与实际观察结果出现偏差时，会触发警报。结果表明，环境变化可在1-7天内导致猪出现呼吸系统疾病症状，这意味着在猪出现呼吸系统疾病（如猪繁殖与呼吸综合征（PRRS），这是一种在猪中常见且具有破坏性的地方性疾病）的负面影响之前，其饲养者有一段时间可以采取行动减轻这种影响。

关键词：异常检测；深度学习；传感器；门控循环单元；猪；健康；疾病

1. 引言

在动物中预测即将到来的健康挑战是维持高水平健康和动物福利的基础。越早预测疾病，就能越早处理，从而降低疾病对动物和农场整体的影响，并提高治疗成功的可能性 [1]。猪繁殖与呼吸综合征（PRRS）、肺炎和胸膜炎等呼吸系统疾病是商业猪群中最常见的疾病类型之一 [2]。因此，能够预测呼吸系统疾病的发生具有极高的价值，我们将其定义为呼吸系统疾病患病率从0增加到大于0的时间点。

影响呼吸系统疾病发生发展的因素有很多，特别是猪所生活的环境。Stark 等人讨论的呼吸系统疾病风险因素中，[2]——具体包括空气质量、温度和湿度——现在能够通过廉价的电子传感器进行实时、高分辨率连续监测

这些数据可用于进一步理解环境条件与呼吸系统疾病之间的关系。

在大多数情况下,连续记录数据意味着存储大量主要描述正常情况的数据,因为异常事件频率较低。生成的正常数据量很大,使我们能够训练一个坚实的正常模型。因此,最好先对正常性进行建模,然后量化任何偏离正常性的情况。

本文的目的是描述和评估一种基于环境因素,对生长猪呼吸系统疾病进行早期预警的方法。一个使用深度学习(门控循环单元(GRU))构建的循环自动编码器,学习如何重建一批猪中不会导致呼吸系统疾病发生的原始传感器数据。然后,该GRU自动编码器(GRU-AE)可以根据其与正常性的接近程度对传感器数据窗口进行“评分”。一个使用粒子群优化(PSO)优化的基于阈值的异常检测器使用此分数来确定是否对分数过高的情况发出警报,因为这些分数代表的环境条件不符合其训练所代表的数据。

使用这种方法的优点在于,无需手工设计特征,正如经典统计方法通常所要求的,这意味着原始传感器数据可以在最少的预处理下使用。此外,不会设置任意阈值,因为异常事件的检测完全是数据驱动的。另外,不需要深入理解环境条件与猪健康之间的关系,因为这一点在网络内部被隐式处理。这项工作被构建为一个异常检测解决方案,而不是例如预测呼吸系统疾病患病率的增加;因此,该方法能够在由低患病率数据组成的集合上运行,而不会影响性能。然而,病例越多,以及这些时候的患病率越高,就越容易微调和验证该方法。

Malhotra等人[3]展示了基于长短期记忆单元(LSTM)的编码器-解码器结构在多传感器异常检测中的潜力,表明该方法对于使用难以预测的数据具有良好的潜力[4]。该实现使用了长短期记忆单元,而不是标准的人工神经网络(ANN)结构,以便处理时间维度,并使用重建误差来确定异常。然而,他们在各种数据集上的实现结果在精确率或召回率(定义在Section 4.1.1)上明显受损。本文重新审视了先前工作中的设计选择,特别是Malhotra等人所做的工作,具体包括:

- 用门控循环单元(GRU)细胞替换长短期记忆(LSTM)细胞
- 将粒子群优化算法引入以优化异常检测器,该检测器用于判断GRU-AE的损失是否异常
- 改变整体系统的评估方式,以展示更均衡的异常检测系统

本文的其余部分结构如下。首先,第2节介绍了所采用方法的背景。第3节解释了数据的组成以及所应用的预处理,随后是第4节,该节详细介绍了每个模型的构建方法。第5节概述了所描述系统的性能,随后是第6节的讨论以及第7节得出的结论。

2. 背景

近年来,农业研究开始逐渐摆脱单纯依赖经典统计方法,转而定期将机器学习(ML)方法,如支持向量机(SVM)和随机森林分类器,纳入数据分析方法中[5–10]。

近期研究已看到支持向量机被用于检测商业母鸡产蛋量生产曲线中的异常,覆盖了多种预测窗口,以实现早期预警系统的目的

的早期预警系统 [5]。其他研究则应用集成学习方法（组合模型）利用气象数据预测禽流感流行情况，显示出比支持向量回归更好的性能 [6]。

分类方法已用于通过单类分类器（OCCs）实现正常与异常的分离。基于支持向量机的方法在此方法中非常常见，尽管有许多潜在方法可以应用。此类模型的灵敏度通常很高，但特异性相对较差 [8]，考虑到这些方法通常用于的数据集的自然不平衡，这是可以预料的。然而，这些指标并不总是适用，特别是当真实负例的数量远远超过假正例的数量时。Cabral等人比较了多种常见的OCCs，并提出了用于单类分类（FBDOCC）心脏病 [8]的特征边界检测方法。

还有分类之外的异常检测方法，如聚类 [11]和相关分析 [12]。聚类使用距离度量来确定新点与聚类质心的距离是否超过可接受值：如果是这样，则被视为异常。然而，属于此类的方法通常无法在分析质量和速度之间取得合理平衡，这是由于时间序列数据的固有特性 [13]。相关分析使用相似性度量来确定新数据是否与已知正常数据相似。

异常检测可用于健康应用，以检测疾病爆发或其他偏离正常的情况。用于此任务的一种常见方法是贝叶斯网络，研究表明其性能优于经典统计方法，例如控制图、移动平均模型和ANOVA回归 [14]。在一项炭疽疫情模拟中 [15]，贝叶斯网络能够在2天内正确触发警报，而移动平均模型需要9天，其他方法则需要11-12天。异常检测非常适合医疗保健领域，因为通常不存在构成问题的特定条件，而是偏离某些条件。例如，通过心电图（ECG）检测心律失常时，不可能了解所有不同类型，因为未来可能会出现新类型 [16]。因此，有必要了解正常状态是什么样子，而不是问题是什么样子。

在传感器用于健康应用的情况下，存在两个主要挑战。首先，不仅需要关注高检测率，还需要关注低误报率 [17]，因为如果误报率高，系统发出的警报将不被信任。其次，虽然并非所有情况下都如此，但异常检测应在近乎实时 [18] 进行，以便快速响应，从而采取干预措施。这给可使用的方法带来了重大限制，因为某些方法非常资源密集。

通常，这些方法需要对数据进行转换，以便生成有用的特征表示 [19–21]。然而，基于深度学习的方法则无需这一步骤。原始数据可以直接输入深度网络，无需手工设计特征，因为特征提取是网络内在功能的一部分 [16]。但这也需要大量数据才能有效运行 [22]。对于高维数据而言，这一点尤其有价值，只要网络足够深能够对数据进行建模，所有数据都能被利用。

农业领域相对较少的工作利用了新兴技术，如深度学习，这些技术主要关注图像分析和遥感 [23]。本文展示了深度学习方法与进化算法结合如何用于时间序列分析，目的是进行异常检测。




图1。一个经典自编码器（左）和由门控循环单元（GRU）组成的循环神经网络（右）的可视化 [24]。这两种方法是我们将它们结合在一起以创建一个能够利用时序性的自编码器（AE）。

自编码器是人工神经网络（ANNs）的一种，它被训练用于重建输入模式（图 1）。给定一个输入张量 N ，找到一个编码 M ，用于创建 N' 。该网络被训练以最小化 N 和 N' 之间的损失。将 N 转换为 M 是编码器，而将 M 尝试重建为 N' 则构成解码器。自编码器在辅助异常检测方面表现出良好性能，通常通过学习特征表示 M 并将其用作 OCC [25–27] 的输入——尽管一些论文利用重建误差来检测异常数据 [28]。

3. 实验设计

3.1. 数据收集

数据是作为欧盟资助的多学科项目的一部分，从欧洲各地的多种农场收集的用于生长猪。每个农场都由一批或多批猪（3-16批）代表，一批猪的种群规模各不相同（40-1294头），并且这些批次被监测了不同的时间长度（14-145天）。猪的初始体重是可变的，范围从17.5到27.6公斤。每批猪中受呼吸系统疾病影响的猪的数量每天都会被记录。呼吸系统疾病的发病率被分为四个严重程度级别，如 Zoetis 的个体猪护理 [29] 所定义。一头猪可以被评分（被确定为患病但未给予治疗）或被治疗，具体取决于其严重程度级别。与健康相关的数据，即表现出疾病症状的猪的数量，是由一名训练有素的人员收集的。他们手动统计了每批中表现出某些疾病症状的猪的数量，并根据症状所属的严重程度级别进行分类。鉴于系统的性质，每天无法识别每头猪的个体身份，因此被归类为表现出症状的猪的数量可能是新病例，也可能是前一天被确定为这样的猪。

环境数据是使用通用警报 [30] 传感器收集的，这些传感器悬挂在存放批次的房间中央。传感器记录了与猪健康相关的环境特征 [31]。简而言之，该系统监测温度（传感器范围为 $-50\text{ }^{\circ}\text{C}$ 至 $+250\text{ }^{\circ}\text{C} \pm 0.05\%$ ）、相对湿度（传感器灵敏度为 $\pm 2\%$ ，工作温度范围为 $-40\text{ }^{\circ}\text{C}$ 至 $+85\text{ }^{\circ}\text{C}$ ），以及 CO_2 浓度（范围从 0 ppm 至 5000 ppm $\pm 30\text{ ppm}$ 或 $\pm 3\%$ 的读数，工作温度范围为 $0\text{ }^{\circ}\text{C}$ 至 $50\text{ }^{\circ}\text{C}$ ，湿度从 0% 至 95%），这些数据每分钟采样一次。

3.2. 数据预处理

异常值被定义为任何超出 $\mu \pm 2\sigma$ 每个变量每个批次范围之外的数据，并从数据中移除。由于移除异常值和硬件问题导致的缺失数据均使用线性插值填充。这被认为是可接受的，因为环境具有低短期方差，这意味着平均而言，两个值之间的非线性变化假设是合理的。传感器数据的预处理结果如图2所示。三个传感器

读数——温度、湿度和CO₂——构成第4节中概述的模型的输入。四种严重程度被汇总并用于计算在特定一天内表现出呼吸系统疾病症状的猪的比例，而不是查看特定的严重程度级别（公式（1））。

$$\text{prevalence} = \frac{\text{Number of pigs showing any symptoms}}{\text{Total number of pigs}} \quad (1)$$

这是因为在大多数情况下，呼吸系统疾病在发展成更严重的症状之前就会被治疗，因此呼吸系统疾病很少超过轻症或中症的分类。所以，在所有农场中，严重或无法恢复的呼吸系统疾病病例非常少。即使合并了数据，患病率仍然非常低，并且随着时间的推移进一步下降（图3）。传感器数据通过将后者（每日健康数据）的分辨率上采样，通过复制值来合并，以覆盖完整的24小时周期。所有输入数据都归一化到0到1之间。




图2。一个箱线图，描述了温度、湿度和CO₂传感器数据，针对数据收集中包含的三个国家——比利时（BE）、塞浦路斯（CY）和西班牙（SP）——在预处理后的情况。




图3。一个图表，显示了呼吸系统疾病在比利时（BE）、塞浦路斯（CY）和西班牙（SP）所有生长猪批次的平均患病率与年龄（以天为单位）的关系，在预处理后。

3.2.1. 假设健康数据与假设异常数据的分离

由于本文研究的是环境对健康的影响，因此有必要考虑环境变化与健康变化之间存在滞后期，因为环境变化不会立即导致疾病爆发 [32]。评估了14天和21天的滞后期 [32]；未使用更长的窗口，因为这会大大减少可用于训练的数据量。这个滞后期被称为假设不健康窗口 u 。使用这个窗口，数据被标记为两个集合之一：“假设健康”和“假设不健康”。当症状出现比例大于0到 u 天后的疾病患病率下降到0时，该点的数据被标记为“假设不健康”；所有其他数据被标记为“假设健康”。此时所有数据都使用滑动窗口分解为30分钟的“帧”。

3.2.2. 将数据分割为训练集、验证集和测试集

需要将数据分割为训练集和测试集。采用留一批次交叉验证方法实现（图4）。我们的方法，详见第4.1节，以及用于对比的GRU回归（GRU-R）模型，详见第4.3.3节，均由两部分组成：GRU网络和基于阈值的异常检测器。GRU网络和异常检测器在完整工作流程中均需要两组数据。 H_t , H_v 用于GRU网络，而 O_e 和 O_t 用于异常检测器。 H_t 用于GRU网络的训练，而 H_v 用于验证它。 O_e 用于通过粒子群优化算法优化异常检测器，而 O_t 是用于获得评估指标的异常检测器测试集。这些集合之间没有任何重叠。

O_t 是一个单一、独立的农场批次， O_e 由三个随机选择的批次组成， H_v 仅包含另一个独立农场批次的假定健康数据，而 H_t 仅包含所有剩余农场批次的假定健康数据。

每个数据集都可以表示为一个矩阵 $X \in \mathbb{R}^{n \times 3}$ ，其中 n 是农场批次中数据分钟数，而每个 X_n 包含温度、湿度和 CO_2 的传感器数据。该矩阵使用大小为 w 的滑动窗口分解为帧，每次移动一个时间点（1分钟），创建 $T \in \mathbb{R}^{m \times w \times 3}$ ，其中 m 是集合中的帧数。




图4。整个处理工作流程的概述，从原始传感器数据到异常检测。温度、 CO_2 和湿度传感器被预处理并合并到每日健康数据中。然后将其分解为四个折叠—— H_t 和 H_v （用于GRU-AE），以及 O_e 和 O_t （用于异常检测）。这些折叠中的每一个都使用30分钟的滑动窗口进行分解。每个30分钟的窗口由GRU-AE处理，并产生一个重建误差。这个重建误差与正常值的距离被用于检测窗口是否异常，使用一个基于阈值的异常检测器，该检测器使用粒子群优化进行优化。

3.2.3. 批量归一化初步实验

批量归一化是一种深度学习技术，通过在输入数据上执行逐层归一化过程，已被证明在训练鲁棒网络方面非常有效。请注意，这里的批量与本文其余部分使用的农场批次含义不同。在这种情况下，批次是训练数据的小块，这些小块被分批输入到正在训练的网络中，随后通过基于反向传播的错误校正。在异常检测中，这种技术的影响不一定是理想的，并且在本次特定应用中，根据初步实验发现会损害性能。这是因为批量归一化允许模型通过对其均值和方差进行归一化来处理内部协变量偏移，这意味着模型更有能力处理它以前从未见过的新数据。使用批量归一化时性能下降表明，模型需要高度敏感于数据中的微小变化，因此它没有被用于最终模型。[33], 这意味着模型更有能力处理它以前从未见过的新数据。使用批量归一化时性能下降表明，模型需要高度敏感于数据中的微小变化，因此它没有被用于最终模型。

4. 时间序列早期预警方法

4.1. GRU自动编码器

自动编码器模型（图4）的实现由两个多层门控循环单元网络组成——一个编码器和一个解码器——它们被同时训练。这不同于传统的ANN结构（图1），后者在数据中不内在地考虑时序性。编码器学习输入 h 的固定大小表示 T 。该表示的质量通过使用它来尝试使用解码器重建 T 来衡量。该模型被优化以最小化重建误差，该误差使用二元交叉熵损失计算， T 和 T' 。 T 在计算损失时被反转，因为它创建了短期依赖关系，这导致序列到序列网络性能提高 [34]。

H_t 被用于使用小批量RMSprop梯度下降训练GRU-AE [35]。该数据集仅包含“假设健康”数据，这导致GRU-AE针对此类数据优化出较低的重建误差，而针对所有其他数据则优化出较高的重建误差。超参数、隐藏层大小、层数、小批量大小、dropout、学习率和动量通过网格搜索选择，并选择了在每次折的交叉熵损失上重建误差最低的参数。隐藏层大小表示GRU-AE为每个给定的时间序列可以存储的信息量。由于这项任务对内存没有大量需求，网格搜索识别出的隐藏层大小预期会相对较小。层数表示GRU创建深度模型和理解时间序列的能力。这些在计算和内存方面都很昂贵。小批量大小是指多少个序列在通过网络进行反向传播之前被前向传递。这通常希望尽可能大以加快训练速度，尽管完全取决于其他参数和可用的内存量。Dropout是一种正则化技术，用于降低过拟合的可能性，在标准人工神经网络中很常见。学习率和动量也在标准人工神经网络中使用。它们决定了在反向传播期间权重变化的剧烈程度。然后使用选定的超参数计算 O_e 和 O_t 中所有帧的重建误差。

一旦所有重建误差都计算完毕，阈值异常检测器被用于判断每帧的重建误差是否应被视为异常。这通过计算给定帧的重建误差 e 与所有帧的重建误差分布 H_v ，即 R ，之间的马氏距离（公式（2））来估计 $COV(e, R)$ 。然后使用局部加权平滑（LOWESS）[36]对距离进行平滑处理。如果平滑后的距离高于某个阈值 τ （其优化方法在4.1.1节中描述），则该帧被视为异常帧。

$$d = \sqrt{(e - \bar{R})^T \Sigma^{-1} (e - \bar{R})} \quad (2)$$

4.1.1. PSO优化异常检测

一旦所有帧的距离都计算完毕，下一步是使用PSO [37]优化阈值异常检测器，该检测器能够判断哪些帧应被视为异常。PSO [37]是一种元启发式算法，它利用群智能的概念来寻找一组超参数，从而得到近乎最优的解决方案。考虑一个序列中所有帧的马氏距离向量 $\vec{D} = \{d_0, d_1, d_2, \dots, d_n\}$ ，其中每个 d_i 是帧索引 i 处的重建误差与 R 之间的马氏距离。任何满足 $d_i : d_{i-1} < \tau \wedge d_i \geq \tau$ 的 d_i 被定义为警报。警报的有效性通过判断疾病在从 $i + \alpha$ 开始到 $i + \beta$ 结束的可接受预测窗口内是否从0增加来评估。如果是，并且没有其他警报因疾病流行率的增加而触发，则该警报被视为真阳性，否则为假阳性。此外，考虑一个向量 $\vec{F} = \{f_0, f_1, f_2, \dots, f_n\}$ ，其中每个 f_i 包含帧 i 显示呼吸系统疾病症状的动物数量。任何满足 $i : f_{i-1} = 0 \wedge f_i > 0$ 且在 $i - \alpha$ 和 $i - \beta$ 之间没有警报的帧被确定为假阴性。

检测器的参数 τ 、 α 和 β 通过PSO进行优化。每个折独立地使用粒子进行优化 O_e ，然后对每个参数的最佳值在 O_t 上进行最终性能评估。每个粒子使用三个维度随机初始化，分别代表 τ 、 α 和 β 。PSO使用的适应度函数（公式（3））旨在最大化马修斯相关系数MCC（公式（4））和 α ，同时最小化 β 。 α 和 β 在输入适应度函数时被归一化到0和1之间。

$$F = 2 \cdot MCC + \alpha - \beta \quad (3)$$

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(FP + FN)(TN + FP)(TN + FN)}} \quad (4)$$

MCC是一个用于评估二元分类器预测的指标，在类别不平衡严重的问题中特别稳健，例如我们的数据集。MCC在完美分类时得分为1，在完美错误分类时得分为 -1 ，在随机分类时得分为0。F-measure在信息/文档检索中常用，因为它不会受到同样的问题影响，但它不包括真负例（true negatives）在计算中。在文档检索中这不是问题，因为它们对该特定任务不重要；但在检测系统中，正确分类负例（真负例）是系统的核心目标之一。

最好能达到高 α ，因为这对应于疾病预警提前程度，而 β 需要最小化，因为这代表预警持续的时间。例如，给定值 $\alpha = 7$ 和 $\beta = 1$ ，我们知道当预警被触发时，预计呼吸系统疾病的发作将在7-8天内出现。对于不同的检测器，给定值 $\alpha = 3$ 和 $\beta = 5$ ，我们知道当预警被触发时，预计呼吸系统疾病的发作将在3-8天内出现，这是一个更大的窗口，因此不确定性也更大。由于我们认为MCC是我们适应度函数最重要的组成部分，它在公式 3. 中具有更大的权重。

4.2. 其他用于评估的指标

特异性，一个常用的评估指标，在包含大量负例（异常检测任务中的典型场景）的数据集中会产生误导性分数。我们未使用特异性，而是采用了阳性预测值（也称为精确率，公式（5））。为简洁起见，本文将此指标称为精确率。我们还使用了灵敏度（也称为召回率，公式（6）），本文将其称为召回率。我们没有使用

精确率或召回率来优化检测器的超参数。它们仅用于评估每种方法的最终性能。

$$P = \frac{tp}{tp + fp} \quad (5)$$

$$R = \frac{tp}{tp + fn} \quad (6)$$

4.3. 用于比较的方法

所有使用的方法都在相同的测试集上进行了测试 O_t 。一旦所有用于比较的方法都完成，就进行了Wilcoxon检验，以比较三种比较方法与GRU-AE之间的精确率、召回率和MCC。这些结果使用Holm方法进行了多重观察校正 [38]。

4.3.1. Luminol

为了提供性能比较的基线，使用了LinkedIn的开源、单变量时间序列异常检测包Luminol [39]。该库代表了开箱即用的异常检测，以及需要数据为单变量的方法，通常通过主成分分析（PCA）实现。它使用单变量时间序列的位图表示，该表示使用符号聚合近似（SAX）计算——这是一种时间序列数据离散化方法 [40]——来检测异常 [41]。这是通过两个连接的窗口实现的，一个滞后窗口和一个领先窗口，它们在时间序列上滑动。每个窗口然后被转换为SAX表示，并随后根据每个SAX子词的频率转换为位图。计算两个位图之间的距离，并代表领先窗口的异常分数。计算出的异常分数然后使用与评估GRU-AE相同的方式使用网格搜索优化的基于阈值的异常检测器进行测试。为了将三个环境变量转换为单变量时间序列，取了第一个主成分。

4.3.2. 时间序列回归与自回归积分移动平均（ARIMA）

自回归积分移动平均（ARIMA）是统计分析中用于单变量时间序列分析的常用模型。该模型的参数（ p ，自回归模型的阶数； d ，差分阶数；以及 q ，移动平均模型的阶数）通过在 H_t 上进行网格搜索找到，以优化最低的赤池信息量标准（AIC）。这是一个用于比较统计模型拟合优度的指标，但它不是拟合优度的度量。找到最优参数后，使用 H_v 对模型进行拟合。然后使用它来预测30分钟窗口，给定前180分钟在 O_e 中的数据。预测窗口与真实值之间的均方误差超过某个阈值（ τ ）的窗口被视为对窗口 $i + \alpha$ 到 $i + \alpha + \beta$ 的警报。 τ 、 α 和 β 的值通过网格搜索优化，最后在 O_t 上进行测试。与Luminol方法类似，取第一主成分将三个环境变量转换为单变量时间序列。

4.3.3. T 使用GRU网络的时间序列回归 (GR U-R)

为了提供关于GRU-AE与另一种深度学习方法相比表现如何的背景，使用了一个GRU网络进行回归。该网络被训练以预测环境传感器未来的值。通过仅使用健康数据 H_t 训练这个回归网络，它学会了预测不会导致呼吸系统疾病发生的条件下的环境变量。该模型被训练以预测30分钟窗口，与GRU-AE使用的窗口大小相同。类似于ARIMA模型，均方误差超过某个阈值（ τ ）的窗口被视为对窗口 $i + \alpha$ 到 $i + \alpha + \beta$ 的警报。类似于

第4.1节中概述的配置，这些参数使用粒子群优化算法进行了优化，该算法使用 O_e 进行训练，并最终在 O_t 上进行评估。

5. 结果

为探索目的，GRU-AE的异常检测器最初使用网格搜索进行了优化，其中固定使用 O_o 作为测试集。从 $\alpha = 10$ 开始，警报总数呈稳定且持续的下降（图5）。这表明可接受的预测窗口已超出可用数据范围，导致部分警报在有效性方面无法验证。警报的减少表明可接受的预测窗口的最大范围 $\alpha + \beta = 16$ 。该最大端点用于缩小PSO的搜索空间，因此，如果 $\alpha + \beta > 16$ ，则粒子被视为无效。搜索空间还通过规定如果粒子超出以下范围则无效来限制： $0 \leq \tau \leq 20$ 、 $1 \leq \alpha \leq 12$ 和 $1 \leq \beta \leq 6$ 。对 τ 的限制涵盖了所有可行值；这是通过初步测试发现的。 β 限制为最大6，因为大于此范围的值被认为太大。

如第 4.1 节所述，采用网格搜索方法来确定GRU-AE的超参数。网格搜索在几乎所有批次中都收敛到相同的参数集，因此，为了节省篇幅，我们在表 1 中报告了所有超参数出现频率最高的值。正如预期，隐藏层大小非常小。这是因为健康状态下环境变化很小，因此只需要少量内存。只有当出现偏离这种情况时——频繁或剧烈的变化——才会出现呼吸系统疾病。

表1。用于训练多维时间序列数据的GRU-AE的网格搜索优化超参数。

超参数	值
隐藏层大小	4
层数	20
小批量大小	1024
dropout	0.5
学习率	1×10^{-6}
动量	0.3




图5。给定警报窗口起始时间为 α 天和大小为 $\beta = 7$ 时，平均触发的警报数量，使用通过网格搜索在马氏距离异常检测上找到的最优阈值 τ （针对每个给定的 α ），该异常检测由基于GRU的自动编码器产生。

表2展示了三种方法的批次性能；每一行展示了当使用某个批次进行测试时，三个比较系统的性能。GRU-AE在所有性能指标（精确率、召回率和MCC）上都优于其他方法。GRU-AE与其他方法最显著的区别在于精确率和召回率上的性能大幅提升；ARIMA也实现了这一点，但程度要低得多。在Luminol和GRU-R模型中，精确率高于召回率，表明这些模型在警报方面更为保守。然而，在GRU-AE模型中，找到的解决方案倾向于以牺牲精确率为代价来最大化召回率， $\mu_P = 0.776$ $\mu_R = 0.938$ ，但并未严重牺牲模型的总体性能。GRU-AE模型显著更高的召回率表明其能够识别导致猪出现呼吸系统疾病症状的环境负面变化；模型的精确率较低可能表明并非所有环境负面变化都会导致呼吸系统疾病的发生。这一点有事实支持，即除了本次分析中使用的环境测量指标外，还有其他因素 [42] 导致呼吸系统疾病的发生。

表2的最后行包含了所有方法在各个批次中的性能高级定量总结。我们统计了每种方法获得MCC（MCC）错误分数0（I）、正确分数1（C）或介于0和1之间（B）的批次数。在C计数方面，Luminol明显是所有方法中表现最差的，而其他方法得分相似（10–11）。同时，GRU-AE的I计数最低，是ARIMA和GRU-R得分的两倍，几乎是Luminol的四倍，同时B计数也最低。

从数值上看，我们至少可以看到Luminol和GRU-AE之间的性能差异可能很大。然而，Wilcoxon检验的结果显示，在精确率（ $p = 0.184$ ）、召回率（ $p = 0.059$ ）和MCC（ $p = 0.054$ ）方面，差异没有统计学意义。Wilcoxon检验还得出结论，ARIMA模型和GRU-AE模型、GRU-R和GRU-AE模型在性能指标方面没有显著差异。

仅观察无事件（表2）的测试批次，深度学习模型在判断无需发出警报方面表现出色，实现了极高的精确率和召回率。这表明GRU能够很好地建模“正常”状态的基础表示，因为当不应发出警报时，模型确实不会发出警报。对于事件数量大于零的批次，ARIMA模型在精确率方面优于两种基于GRU的模型。然而，这是以召回率大幅牺牲为代价的，表明模型可能能力不足。两种基于GRU的模型在精确率方面性能均有所下降，但只有GRU-AE能够保持其高召回率。每个批次的优化 α 和 β 值见表3。

表2. 表为网格搜索优化的领英异常检测库 (Luminol)、网格搜索优化的自回归集成移动平均 (ARIMA) 模型、基于GRU的回归损失 incurredfrom 的PSO优化阈值异常检测, 以及基于GRU自动编码器产生的马氏距离的PSO优化阈值异常检测的结果。事件列显示呼吸系统疾病在批次中从0增加的次数, P表示精确率, R是模型的召回率。这些结果来自测试数据 O_t 。最终的I/B/C行表示错误 ($MCC = 0.0$)、介于 ($0.0 < MCC < 1.0$) 或正确 ($MCC = 1.0$) 的折数。

ID	事件	Luminol			ARIMA			GRU-R			GRU-AE		
		P	R	MCC	P	R	MCC	P	R	MCC	P	R	MCC
5	0	0.111	0.125	0.118	1.0	1.0	1.0	1.0	1.0	1.0	0.0	0.0	0.0
9	0	1.0	0.1	0.316	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
10	0	0.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0	0.0	1.0	1.0	1.0
14	0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
16	0	1.0	1.0	1.0	0.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0
17	0	1.0	0.667	0.816	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
18	0	1.0	1.0	1.0	0.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0
19	0	1.0	0.667	0.816	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
24	0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
26	4	1.0	0.667	0.816	0.053	0.5	0.162	1.0	0.0	0.0	0.250	1.0	0.500
27	5	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.111	1.0	0.333
28	3	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	1.0	1.0	1.0
29	1	0.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0
30	0	0.0	0.0	0.0	0.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0
31	1	0.0	0.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0	0.050	1.0	0.224
32	0	0.0	0.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
平均事件 = 0		0.647	0.505	0.551	0.727	1.000	0.727	0.909	0.909	0.909	0.909	0.909	0.909
平均事件 > 0		0.200	0.133	0.163	0.811	0.500	0.432	0.400	0.400	0.200	0.482	1.000	0.411
平均所有		0.507	0.390	0.430	0.753	0.844	0.635	0.750	0.688	0.688	0.776	0.938	0.754
I/B/C		7/5/4			5/1/10			5/0/11			2/3/11		

表3。 表为网格搜索优化的领英异常检测库（Luminol）、网格搜索优化的ARIMA模型、基于GRU的回归损失PSO优化阈值异常检测以及基于GRU自动编码器马氏距离PSO优化阈值异常检测的结果。 α 和 β 分别表示评估警报的时间窗口的起始和长度（以天为单位）， τ 是需要超过的损失/马氏距离阈值以触发警报。它们使用训练数据 O_e 进行优化；这些结果来自测试数据 O_{t_e} 。

ID	事件	Luminol ARIMA				GRU-R		GRU-AE	
		α	β	α	β	α	β	α	β
5	0	12	4	12	1	1	6	1	1
9	0	12	4	12	1	1	6	1	2
10	0	12	4	12	1	1	6	1	2
14	0	12	4	12	1	1	6	1	4
16	0	12	4	12	1	1	6	3	1
17	0	12	4	12	1	1	6	1	5
18	0	12	4	12	1	1	6	3	5
19	0	12	4	12	1	1	6	1	5
24	0	12	4	12	1	1	6	1	6
26	4	12	4	12	1	2	6	3	6
27	5	12	4	12	4	4	6	1	6
28	3	12	4	12	1	5	6	8	6
29	1	12	4	12	2	1	6	2	6
30	0	12	4	12	1	1	6	4	6
31	1	12	4	12	1	1	6	1	6
32	0	12	4	12	1	1	6	8	5

5.1. 案例研究

以下案例以第27批次为例，说明了应用于该问题的每种方法的特点。该批次被选中，因为它包含单个批次中异常事件数量最多，是方法表现较好的更具挑战性的批次之一。该批次通过Luminol驱动、网格搜索优化的异常检测（图6）进行分析，ARIMA驱动、网格搜索优化的异常检测（图7），GRU-R驱动、粒子群优化算法优化的异常检测（图8），以及GRU-AE驱动、粒子群优化算法优化的异常检测（图9）。每个图的第一个子图显示了呼吸系统疾病在模拟和二进制形式中的流行情况；第二个子图绘制了用于异常检测的单变量时间序列及其产生的警报。对于Luminol模型，这是温度、湿度和CO₂ 时间序列的第一主成分。对于GRU-R和ARIMA模型，使用预测值与真实值之间的均方误差；对于GRU自动编码器，使用每个输入窗口与模型重建之间的二元交叉熵损失。最后一个子图显示了每个警报的异常检测结果及其警报窗口。

这两种基于深度学习的模型在底层技术方面显示出一致性，因为它们都能在环境数据中捕捉到相似的事件，这在损失曲线中的共同峰值和谷值中得到了证明。基于Luminol的模型能够正确地对部分呼吸系统疾病高发情况进行警报，但这些警报被其产生的大量误报远远超过了。而GRU-R和ARIMA模型则存在相反的问题，即即使后者在初看时似乎产生了一些显著的异常点，但也没有发出任何警报。这些点很少与实际事件相符，ARIMA模型的成功很大程度上归功于它几乎不发出任何警报。然而，GRU自动编码器模型在这两种解决方案之间取得了平衡，它对几乎所有呼吸系统疾病的发生情况都发出了警报，尽管存在一些误报，但数量远少于基于Luminol的模型。




图6。使用Luminol驱动异常检测处理批次27的结果，考虑了其网格搜索优化的参数 α （警报窗口的起始位置）和 β （窗口长度），与单个批次中呼吸系统疾病的流行率之间的关系。



图7。使用ARIMA驱动异常检测处理批次27的结果，考虑了其网格搜索优化的参数 α （警报窗口的起始位置）、 β （窗口长度）和 τ （预测值与实际值之间的损失必须跨越的阈值，才能被视为警报），与单个批次中呼吸系统疾病的流行率之间的关系。



图8。使用GRU-R驱动异常检测（基于PSO优化参数 α （警报窗口的起始位置）、 β （窗口长度）和 τ （预测值与实际值之间的损失必须跨越的阈值以被视为警报）处理批次27的结果，与单个批次中呼吸系统疾病的流行率的关系。




图9。使用GRU自动编码器驱动异常检测（基于PSO优化参数 α （警报窗口的起始位置）、 β （窗口长度）和 τ （预测值与实际值之间的损失必须跨越的阈值以被视为警报）处理批次27的结果，与单个批次中呼吸系统疾病的流行率的关系。

5.2. 门控循环单元-自动编码器层数对性能的影响

编码器和解码器中使用的层数对GRU-AE能够建模的内容有影响(图10)。由于模型背后的概念是“健康”数据的损失会减少,因此完美环境的损失会随时间保持恒定,这意味着模型架构应该选择以最小化健康数据中的损失标准差。使用较少的层数,1-15层,GRU-AE建模“健康数据”的能力几乎没有变化。一旦GRU-AE每半部分的层数达到20层,性能达到最大值,并且不会进一步降低损失的标准差。




图10。GRU-AE中不同层数如何影响建模环境的能力数据。标准差越小,模型性能越好。

al

5.3. 计算时间

尽管性能有所欠缺,所提出的基于Luminol的模型(图6)在训练和优化上所需时间仅为所提出的两个门控循环单元模型所需时间的一小部分。基于Luminol的模型在6小时内完成完全训练,而基于ARIMA的模型在24小时内完成完全训练。这些模型在一台配备两个Xeon E5-2699v4处理器(总共44个核心)的机器上运行,而两个门控循环单元模型则在一台性能相似、配备Nvidia GTX 980 Ti的机器上花费了一周时间。

6. 讨论

本文旨在开发并评估一种利用包含门控循环单元的循环神经网络的方法,并将该方法应用于生长猪呼吸系统疾病的早期检测。该网络结构被用于构建一个自编码器,该自编码器能够在网络结构本身中考虑数据的时序性,而不仅仅是通过数据的结构化。GRU-AE在存在需要检测的事件时,具体表现优于GRU-R,从而为GRU-AE带来了显著更高的召回率。

这项工作的创新之处在于对Malhotra等人提出的用于多传感器异常检测的循环自编码器想法进行了全面重新评估。主要调整是将目前循环网络中最常用的LSTM单元切换为GRU。这对整个网络都有益,因为GRU更简单,因此更高效,同时性能相当[43–46]。此外,还创建了一个PSO优化异常检测器,用于处理GRU-AE的输出,以确定一个窗口是否异常。除了方法论上的变化,这项工作还通过案例研究和与其他替代方法的实际比较,对GRU-AE的性能进行了更深入的评估,并将该方法应用于真实世界数据。

通过案例研究和与其他替代方法的实际比较,对 GRU-AE 的性能进行了更深入的评估,并将该方法应用于真实世界数据。

鉴于畜牧业最近的趋势,人们正朝着自动化畜牧业管理和监测的重大部分迈进,以应对对高质量、可持续和安全肉类生产日益增长的需求 [47]。这些畜牧业管理的变化为疾病检测自动化提供了机会,例如这里开发的方法。一种普遍采用的方法,通常被称为精准畜牧业 farming (PLF),是引入各种传感器。小型、相对便宜、高分辨率的传感器可以监测环境变量,例如本研究中评估的变量,并使用摄像头等传感器捕获大量其他数据 [48] 和麦克风 [49]。在疾病检测的情况下,任何假阴性都有可能导致流行病,因此会增加畜牧业系统的疾病风险。出于这个原因,如果可以实现更高的召回率,就应该牺牲精确率,因为在这种情况下,假阳性带来的危险小于假阴性。本文提出的 GRU-AE 正是作用于这一点,确保尽可能最大化召回率。

开发这种方法的动机是处理收集到的数据中疾病患病率非常低的问题。在这项工作中,我们专注于呼吸系统疾病的检测。有几个原因促使我们这样做,其中包括该数据集中这类猪的呼吸系统疾病患病率最高。我们也有其他影响猪的疾病的数据,如跛行和消化系统疾病,但由于它们的发病率远低于呼吸系统疾病,开发类似的方法会导致模型验证的样本数量不足。

为应对数据带来的挑战,我们采取了措施,例如将所有呼吸系统疾病的分类(轻微、轻度、严重和不可恢复)合并,如第3.2节所述。这是合理的,因为这种方法是用于预警系统,只需要知道是否有疾病或没有疾病。因此,将呼吸系统疾病患病率作为一个整体来看,而不是按严重程度分段,可以创建一个更简单、更专注于所解决问题挑战的数据集。需要注意的是,这里开发的方法可以应用于猪的所有类型呼吸系统疾病。

环境条件变化后呼吸系统疾病的检测符合文献中推导的参数,即我们在病原体潜伏期之前(例如,PRRS的平均潜伏期为14天 [32])不会预测即将到来的疾病。GRU-R和GRU-AE均能够在批次中的猪首先出现症状前1-7天发出即将发生呼吸系统疾病的警报。然而,Luminol模型无法反映这一点,这可能是由于其无法找到导致强MCC的超参数。这导致PSO最大化 α 和 β 的值,因为如果性能差,这样做没有后果。

由于RNN-based模型在自然语言处理等领域表现出色,其用于序列分析的新兴流行导致需要方法来提高这些黑盒模型的可解释性。该领域的工作已稳步增长 [50,51],未来的研究可以考虑将此类方法应用于模型,以基于GRU-AE更好地理解生长猪呼吸系统疾病的风险因素。由于该方法无假设且不考虑国家差异,额外的工作来验证这种多传感器异常检测是否超越农业健康领域,从而验证其鲁棒性,将对该领域社区具有重要价值。

7. 结论

我们提出了一种基于深度学习的模型,能够对生长猪呼吸系统疾病的早期发生发出预警。所提出的基于GRU的自动编码器与PSO优化异常检测器相结合的方法,在检测将导致生长猪发生呼吸系统疾病的异常方面显示出强大的潜力,并且对特定国家环境具有鲁棒性。这种GRU-AE能够优于其他可比方法

在精确率、召回率和整体性能方面,无论是在存在疾病或不存在疾病的情况下。

作者贡献: 概念化、数据管理、形式分析、调查、方法、软件、验证、可视化以及撰写—原始草稿准备: J.C.; 数据管理、资助获取、调查、项目管理、资源、监督、验证、撰写审阅和编辑: I.K.; 概念化、方法、撰写—审阅和编辑以及监督: T.P.; 概念化、方法、验证、撰写—审阅和编辑以及监督: J.B.

资助: 这项工作是在PROHEALTH项目下进行的。PROHEALTH项目获得了欧盟第七框架计划(用于研究、技术开发和示范)的资助,资助协议号为613574。

致谢: 这项研究使用了纽卡斯尔大学的Rocket高性能计算服务。

利益冲突: 作者声明无利益冲突。

参考文献

1. Huhn, R. 猪地方流行性肺炎: 发病率及其对体重增率的影响。美国兽医研究杂志 1970, 31, 1097–1108。 [PubMed]
2. Stärk, K.D. 环境风险因素对猪呼吸系统疾病影响的流行病学调查——文献综述。兽医杂志 2000, 159, 37–56。 [CrossRef] [PubMed]
3. Malhotra, P.; Ramakrishnan, A.; Anand, G.; Vig, L.; Agarwal, P.; Shroff, G. 基于LSTM的编码器-解码器用于多传感器异常检测。在线获取: <https://arxiv.org/abs/1607.00148> (访问于2018年6月20日)。
4. Malhotra, P.; Vig, L.; Shroff, G.; Agarwal, P. 长短期记忆网络用于时间序列异常检测。载于会议论文集; 鲁汶大学出版社: 比利时鲁汶, 2015; 第89页。
5. Morales, I.R.; Cebrián, D.R.; Blanco, E.F.; Sierra, A.P. 商业蛋鸡产蛋曲线的早期预警: 一种支持向量机方法。农业电子计算 2016, 121, 169–179。 [CrossRef]
6. Singh, R.K.; Sharma, V.C. 使用机器学习技术进行人畜共患病预测的集成方法; 印度管理学院: 印度艾哈迈达巴德, 2015。
7. Valdes-Donoso, P.; VanderWaal, K.; Jarvis, L.S.; Wayne, S.R.; Perez, A.M. 使用机器学习预测美国区域控制传染病计划内的猪活动。兽医学前沿 2017, 4, 2。 [CrossRef] [PubMed]
8. Cabral, G.G.; de Oliveira, A.L.I. 用于心脏病诊断的单类分类。载于IEEE国际系统、人与 cybernetics 会议 (SMC) 论文集, 美国加利福尼亚州圣地亚哥, 2014年10月5日至8日; 第2551–2556页。
9. Leng, Q.; Qi, H.; Miao, J.; Zhu, W.; Su, G. 极限学习机的单类分类。工程数学问题 2015, 2015。 [CrossRef]
10. Thompson, R.; Matheson, S.M.; Plötz, T.; Edwards, S.A.; Kyriazakis, I. 猪测谎仪: 使用惯性传感器自动量化母猪姿势状态和转换。农业电子计算 2016, 127, 521–530。 [CrossRef] [PubMed]
11. Münz, G.; Li, S.; Carle, G. 使用k均值聚类进行交通异常检测。载于GI/ITG Workshop MMBnet, 汉堡大学: 德国汉堡, 2017; 第13–14页。
12. Ambusaidi, M.A.; Tan, Z.; He, X.; Nanda, P.; Lu, L.F.; Jamdagni, A. 基于非线性相关度量的入侵检测方法。国际互联网协议技术杂志 2014, 8, 77–86。 [CrossRef]
13. Aghabozorgi, S.; Shirkhorshidi, A.S.; Wah, T.Y. 时间序列聚类——十年综述。信息系统 2015, 53, 16–38。 [CrossRef]
14. Wong, W.K.; Moore, A.W.; Cooper, G.F.; Wagner, M.M. 贝叶斯网络异常模式检测用于疾病爆发。载于第20届国际机器学习会议 (ICML-03) 论文集, 美国华盛顿特区, 2003年8月21日至24日; 第808–815页。
15. Wong, W.K.; Moore, A.; Cooper, G.; Wagner, M. 最近事件中的异常 (WSARE): 一种早期检测疾病爆发的算法。机器学习研究杂志 2005, 6, 1961–1998。

16. Chauhan, S.; Vig, L. **异常检测**在ECG时间信号中通过深度长短期记忆网络。在IEEE国际会议数据科学与高级分析 (DSAA) 论文集中, 巴黎, 法国, 2015年10月19日至21日; 第1-7页。
17. Haque, S.A.; Rahman, M.; Aziz, S.M. 无线传感器网络中的传感器**异常检测**用于医疗保健。Sensors 2015, 15, 8764–8786. [CrossRef] [PubMed]
18. Veeravalli, B.; Deepu, C.J.; Ngo, D. 流式数据中可穿戴医疗设备的实时个性化**异常检测**。在智能医疗保健中大规模分布式计算手册; Springer: 柏林, 德国, 2017年; 第403-426页。
19. Kanarachos, S.; Mathew, J.; Chroneos, A.; Fitzpatrick, M. 使用小波、神经网络和Hilbert变换的时间序列数据**异常检测**。在第六届IEEE信息、智能、系统和应用国际会议 (IISA2015) 论文集中, 科孚, 希腊, 2015年7月6日至8日; 第1-6页。
20. Li, J.; Pedrycz, W.; Jamal, I. 多变量时间序列**异常检测**: 一个隐藏马尔可夫模型框架。Appl. Soft Comput. 2017, 60, 229–240. [CrossRef]
21. Chuah, M.C.; Fu, F. ECG**异常检测**通过时间序列分析。在国际并行和分布式处理与应用会议论文集中, 尼亚加拉瀑布, 安大略省, 加拿大, 2007年8月28日至9月1日; 第123-135页。
22. Chen, X.W.; Lin, X. 大数据深度学习: 挑战与前景。IEEE Access 2014, 2, 514–525. [CrossRef]
23. Kamilaris, A.; Prenafeta-Boldú, F.X. 农业中的深度学习: 一项调查。Comput. Electron. Agric. 2018, 147, 70–90. [CrossRef]
24. Veen, F.V. 神经网络的一个大致完整的图表; The Asimov Institute: 乌得勒支, 荷兰, 2016年。
25. Lv, Y.; Duan, Y.; Kang, W.; Li, Z.; Wang, F.Y. 基于大数据的交通流量预测: 一种深度学习方法。IEEE Trans. Intell. Transp. Syst. 2015, 16, 865–873. [CrossRef]
26. Andrews, J.T.; Morton, E.J.; Griffin, L.D. 使用自编码器检测异常数据。Int. J. Mach. Learn. Comput. 2016, 6, 21.
27. Rahman, A.; Smith, D.; Hills, J.; Bishop-Hurley, G.; Henry, D.; Rawnsley, R. 自编码器和统计特征用于牛行为分类的比较。在国际联合神经网络会议 (IJCNN) 论文集中, 温哥华, 不列颠哥伦比亚省, 加拿大, 2016年7月24日至29日; 第2954–2960页。
28. Al Moubayed, N.; Breckon, T.; Matthews, P.; McGough, A.S. 使用概率主题建模和堆叠降噪自编码器进行短信垃圾邮件过滤。在国际神经网络会议论文集中, 巴塞罗那, 西班牙, 2016年9月6日至9日; 第423–430页。
29. Zoetis. 个体猪护理; Zoetis: 帕里斯帕尼 - 特洛伊山, 新泽西州, 美国, 2012年。
30. Alert, G. 应用领域。在线可用: <http://www.general-alert.com/Applications> (于2018年4月30日访问)。
31. Whittemore, C.T.; Kyriazakis, I. Whittemore的猪生产科学与实践; John Wiley & Sons: 霍博肯, 新泽西州, 美国, 2006年。
32. 世界动物卫生组织。感染猪繁殖与呼吸综合征病毒; 世界动物卫生组织: 巴黎, 法国, 2014年。
33. Ioffe, S.; Szegedy, C. 批标准化: 通过减少内部协变量偏移来加速深度网络训练。arXiv 2015, 预印本 arXiv:1502.03167.
34. Sutskever, I.; Vinyals, O.; Le, Q.V. 使用神经网络的序列到序列学习。在神经信息处理系统进展中; Curran Associates, Inc.: 纽约, 纽约, 美国; 2014年; 第3104–3112页。
35. Tieleman, T.; Hinton, G. 讲座6.5-rmsprop: 将梯度除以其最近幅度的运行平均值。COURSERA神经网络机器学习 2012, 4, 26–31.
36. Cleveland, W.S. 稳健局部加权回归和散点图平滑。J. Am. Stat. Assoc. 1979, 74, 829–836. [CrossRef]
37. Shi, Y.; Eberhart, R. 一种改进的粒子群优化器。在IEEE国际进化计算会议论文集中, IEEE计算智能世界大会, 安克雷奇, 阿拉斯加, 美国, 1998年5月4日至9日; 第69–73页。
38. Holm, S. 一种简单的顺序拒绝多重检验程序。Scand. J. Stat. 1979, 6, 65–70.
39. LinkedIn. Luminol. 2016年。在线可用: <https://github.com/linkedin/luminol> (于2018年4月30日访问)。

40. 林杰; Keogh, E.; 魏力; Lonardi, S. Experiencing SAX: 一种新的时间序列符号表示方法. 数据挖掘与知识发现 2007, 15, 107–144. [CrossRef]41. 魏力; Kumar, N.; Lolla, V.N.; Keogh, E.J.; Lonardi, S.; Ratanamahatana, C.A. 时间序列无假设异常检测. 在第 5 卷, 第 237–242 页的“国际科学和统计数据库管理会议论文集”, 美国加利福尼亚州拉霍亚, 2005 年 6 月 29 日–7 月 1 日. 42. Mortensen, S.; Stryhn, H.; Søgaard, R.; Boklund, A.; Stärk, K.D.; Christensen, J.; Willeberg, P. 猪繁殖与呼吸综合征 (PRRS) 病毒感染母猪群的风险因素. 兽医预防医学 2002, 53, 83–101. [CrossRef]43. Chung, J.; Gulcehre, C.; Cho, K.; Bengio, Y. Gated Recurrent Neural Network 在序列建模中的经验评估. 在线获取: <https://arxiv.org/abs/1412.3555> (访问于 2018 年 2 月 12 日). 44. Chung, J.; Gulcehre, C.; Cho, K.; Bengio, Y. Gated Feedback Recurrent Neural Network. 在第 5 卷, 第 2067–2075 页的“国际机器学习会议论文集”, 法国里尔, 2015 年 7 月 6–11 日. 45. Karpathy, A.; Johnson, J.; Li, F.-F. 可视化和理解循环网络. 在线获取: <https://arxiv.org/abs/1506.02078> (访问于 2018 年 3 月 17 日). 46. Jozefowicz, R.; Zaremba, W.; Sutskever, I. 循环网络架构的经验探索. 在第 5 卷, 第 2342–2350 页的“国际机器学习会议论文集”, 法国里尔, 2015 年 7 月 6–11 日. 47. Berckmans, D. 精准畜牧业技术在密集型畜牧业系统中的福利管理. 国际动物流行病学科学技术报告 2014, 33, 189–196. [CrossRef]48. Matthews, S.G.; Miller, A.L.; Clapp, J.; Plötz, T.; Kyriazakis, I. 通过自动检测猪的行为变化来早期发现健康和福利问题. 兽医杂志 2016, 217, 43–51.[CrossRef] [PubMed]49. Chung, Y.; Oh, S.; Lee, J.; Park, D.; Chang, H.H.; Kim, S. 使用音频监控系统的声音数据自动检测和识别猪的消耗性疾病. 传感器 2013, 13, 12929–12942. [CrossRef] [PubMed]50. Krakovna, V.; Doshi-Velez, F. 使用隐藏马尔可夫模型提高循环神经网络的解释性. 在线获取: <https://arxiv.org/abs/1606.05320v2> (访问于 2017 年 12 月 29 日). 51. Samek, W.; Wiegand, T.; Müller, K.R. 可解释人工智能: 理解、可视化和解释深度学习模型. 在线获取: <https://arxiv.org/abs/1708.08296> (访问于 2018 年 3 月 23 日).



© 2018 由作者发表。许可证为MDPI, 瑞士巴塞尔。本文为开放获取文章, 在 Creative Commons Attribution (CC BY) 许可协议 (<http://creativecommons.org/licenses/by/4.0/>) 的条款和条件下发布。